

# Raport 1

Romana Żmuda

1 04 2020

**Wprowadzenie zmiennych z pliku dane1.txt do Tabeli “Moje Dane”, jak również poprawne ustawienie i nazwanie zmiennych.**

```
setwd(datapath)
MojeDane<-read.table("dane1.txt",skip = '13' ,blank.lines.skip = TRUE, fill = TRUE, header = FALSE)
colnames(MojeDane)<-c('edukacja','miejscezam','płeć','doświadczenie','związek','zarobki','wiek','rasa',
```


## Zadanie 1

W tej sekcji mamy do analizy dane z tabeli Moje Dane o nazwie typ, w której to przeanalizowałam 6 typów zawodów. Następnie na wykresie kołowym umieściłam dane procentowe, jak również nazwy 6 zawodów: kierownik, sprzedawca/marketing, urzędnik, obsługa, wolny zawód, inne.

Po wstępnej analizie danych widzimy, jak rozkłada się ilościowy podział (534 osób) na konkretne zawody: 55 kierownik, 38 sprzedawca, 97 urzędnik, 83 obsługa, 105 wolny zawód, 156 inne. Wykres kołowy prezentujący procentowy udział każdego z zawodów.

```
zawody<-c(praca1,praca2,praca3,praca4,praca5,praca6)
suma_zawody<-sum(zawody)
procenty_zawody<-round(100*zawody/suma_zawody,1)
labels<-c("Kierownik","Sprzedawca","Urzędnik","Obsługa","Wolny zawód","Inne")
labels<-paste(labels,procenty_zawody)
labels<-paste(labels,"%", sep="")
pie(table(MojeDane$praca),labels=labels,main="Rozkład Zawodów")
```

## Rozkład Zawodów



## Zadanie 2

Tabela odpowiednich wartości dla danych pensja, czyli : minimum, pierwszy kwantyl, mediana, średnia, trzeci kwantyl, maksimum.

```
pensja_wartosci<-select(MojeDane,pensja)
summary(pensja_wartosci)
```

```
##      pensja
## Min.   : 4.03
## 1st Qu.: 21.16
## Median : 31.35
## Mean   : 36.37
## 3rd Qu.: 45.34
## Max.   :179.34
```

## Zadanie 3

W tym zadaniu mamy do przeanalizowania dane z kolumny wykształcenie, które dzieli się na 3 podgrupy: 1. Osoba ucząca się do 8 lat. 2.Osoba ucząca się od 8 do 12 lat. 3.Osoba ucząca się ponad 12 lat. Jak również

korelację między wykształceniem, a pensją.


Tabela odpowiednich wartości dla danych wykształcenie po odpowiednim podziale, czyli : minimum, pierwszy kwantyl, mediana, średnia, trzeci kwantyl, maksimum.

```
edu_1<-summary(educacja_1_P)
edu_2<-summary(educacja_2_P)
edu_3<-summary(educacja_3_P)
total<-cbind(edu_1,edu_2,edu_3)
colnames(total)<-c('educacja<=8','8<educacja<=12','educacja>12')
total
```

```
##  edukacja<=8      8<educacja<=12    edukacja>12
##  "Min.   :12.09   " "Min.   : 4.03   " "Min.   : 8.10   "
##  "1st Qu.:17.27   " "1st Qu.:19.44   " "1st Qu.: 25.19   "
##  "Median :21.20   " "Median :27.40   " "Median : 40.30   "
##  "Mean   :24.28   " "Mean   :30.71   " "Mean   : 44.48   "
##  "3rd Qu.:28.21   " "3rd Qu.:38.41   " "3rd Qu.: 56.04   "
##  "Max.   :56.42   " "Max.   :89.47   " "Max.   :179.34   "
```

```
wyksz_pensja<-MojeDane %>% select(wykszt,pensja)
boxplot(pensja ~ wykszt, data = wyksz_pensja, xlab = "Poziom wykształcenia",
        ylab = "Pensja", main = "Zależność pensji od poziomu wykształcenia")
```

## Zależność pensji od poziomu wykształcenia



Zauważmy, iż pensja rośnie wraz z poziomem edukacji, jak również rośnie zakres kwotowy zarobków, więc istnieją spore dysproporcje w średnich zarobkach. Jeśli uczyliśmy się do 8 lat to zarabiamy podobnie w całej naszej grupie, a samo odchylenie nie odbiega od normy. Największe różnice są gdy przekroczyliśmy 12 lat nauki, wtedy istnieje spora szansa wysokich zarobków., jednak spora grupa zarabia poniżej średniej. ## Zadanie 4

```
d<-CrossTable(MojeDane$rasa, MojeDane$wyksz, expected = FALSE)
```

```
##
##
##      Cell Contents
## |-----|
## |              N |
## | Chi-square contribution |
## |      N / Row Total |
## |      N / Col Total |
## |      N / Table Total |
## |-----|
##
##
## Total Observations in Table:  534
```

```
##
##
##      | MojeDane$wyksz
## MojeDane$rasa |      1 |      2 |      3 | Row Total |
## -----|-----|-----|-----|-----|
##      1 |      5 |      37 |      25 |      67 |
##      |      0.767 |      0.181 |      0.580 |      |
##      |      0.075 |      0.552 |      0.373 |      0.125 |
##      |      0.185 |      0.135 |      0.108 |      |
##      |      0.009 |      0.069 |      0.047 |      |
## -----|-----|-----|-----|-----|
##      2 |      8 |      8 |      11 |      27 |
##      |      32.246 |      2.507 |      0.045 |      |
##      |      0.296 |      0.296 |      0.407 |      0.051 |
##      |      0.296 |      0.029 |      0.047 |      |
##      |      0.015 |      0.015 |      0.021 |      |
## -----|-----|-----|-----|-----|
##      3 |      14 |      230 |      196 |      440 |
##      |      3.057 |      0.051 |      0.122 |      |
##      |      0.032 |      0.523 |      0.445 |      0.824 |
##      |      0.519 |      0.836 |      0.845 |      |
##      |      0.026 |      0.431 |      0.367 |      |
## -----|-----|-----|-----|-----|
## Column Total |      27 |      275 |      232 |      534 |
##      |      0.051 |      0.515 |      0.434 |      |
## -----|-----|-----|-----|-----|
##
##
```

```
e<-CrossTable(MojeDane$rasa, MojeDane$wyksz, expected=FALSE, prop.r=FALSE, prop.c=FALSE,
prop.t=TRUE, prop.chisq=FALSE, chisq = FALSE, fisher=FALSE, mcnemar=FALSE,
resid=FALSE, sresid=FALSE, asresid=FALSE,
missing.include=FALSE,format=c("SAS", "SPSS"))
```


```
##
##
##      Cell Contents
## -----|
##      N
##      N / Table Total
## -----|
##
##
## Total Observations in Table:  534
##
##
##      | MojeDane$wyksz
## MojeDane$rasa |      1 |      2 |      3 | Row Total |
## -----|-----|-----|-----|-----|
##      1 |      5 |      37 |      25 |      67 |
##      |      0.009 |      0.069 |      0.047 |      |
## -----|-----|-----|-----|-----|
##      2 |      8 |      8 |      11 |      27 |
##      |      0.015 |      0.015 |      0.021 |      |
## -----|-----|-----|-----|-----|
```

##	3	14	230	196	440
##		0.026	0.431	0.367	
##	-----				
##	Column Total	27	275	232	534
##	-----				
##					
##					

W Pivocie zsumowano liczbę osób różnych nacji z stosunku z poziomem edukacji, w każdej komórce umieszczono odpowiednie podsumowania. W drugiej tabeli mamy samą wartość procentową sumującą się do jedynki, więc aby uzyskać procentowy udział należy pomnożyć razy 100.

## Zadanie 5

Narysowałam histogram dla próby losowej rozmiaru  $n = 1000$  z rozkładu  $N(0,1)$ , umieszczając na nim także wykres gęstości tego rozkładu



Jednak ten wykres nie przybliży najlepiej dlatego obliczamy liczbę klas według reguły Freedmana-Diaconisa


```
max<-max(x)
min<-min(x)
iqr<-IQR(x) # obliczanie mianownika, czyli funkcję h
```

```

liczba_klas<-ceiling(((max - min)*(1000)^(1/3))/2*iqr) # liczba klas,
#czyli na ile podzielić rozkład,
#aby był zbliżony do rozkładu normalnego
hist(x,main="Rozkład normalny w próbie n = 1000 z regułą Freedmana-Diaconis'a",
     freq = FALSE, breaks = liczba_klas)

```

### Rozkład normalny w próbie n = 1000 z reguła Freedmana–Diaconis'a



### Zadanie 6


Rozkład pensji:

```

hist(MojeDane$pensja,main="Histogram prawdopodobieństwa pensji",
     xlab="Pensja",freq = FALSE,xlim=c(0,200),col="pink")

```

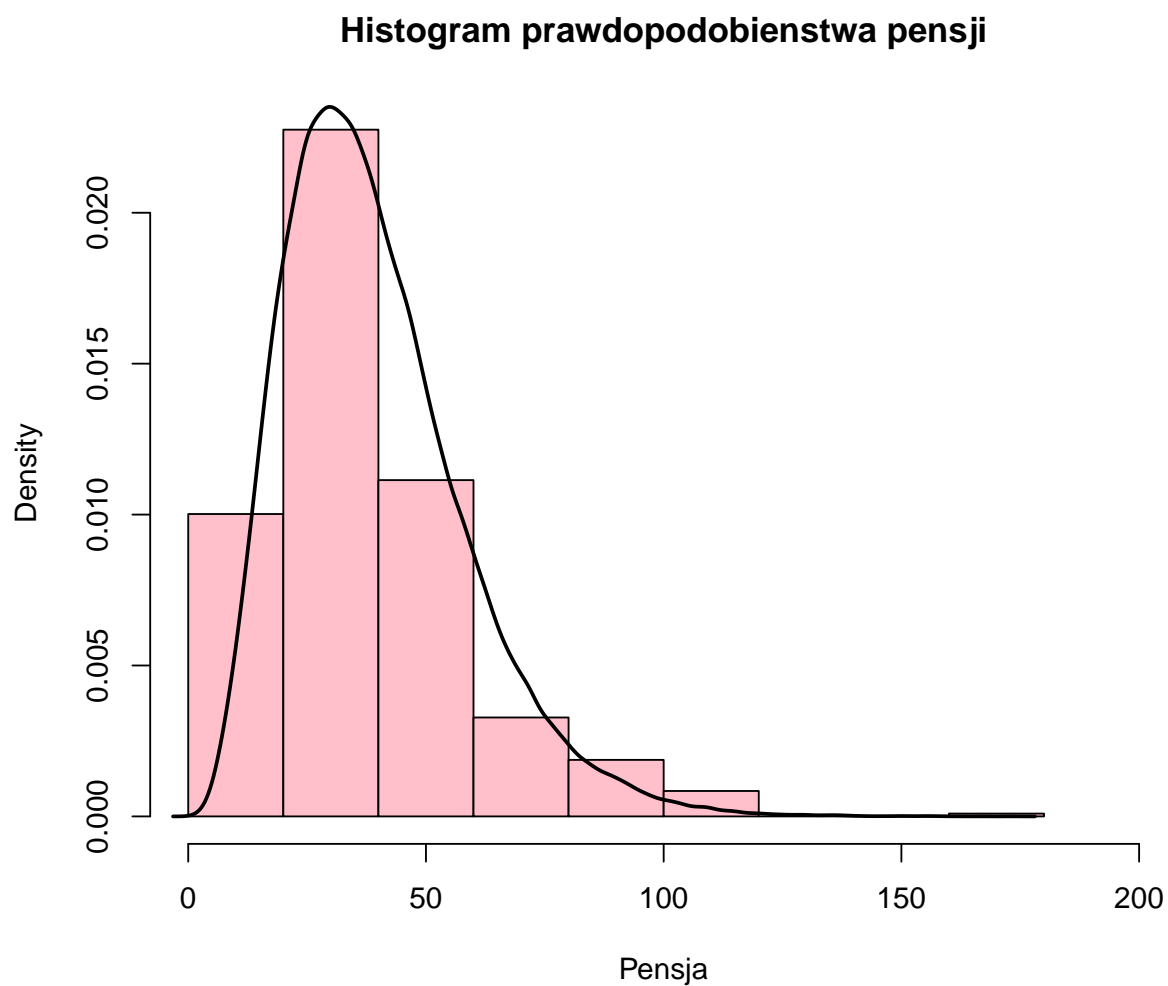
### Histogram prawdopodobieństwa pensji



#### Zadanie 7

```
k<-rgamma(100000, shape=4.35, scale =9)
hist(MojeDane$pensja,main="Histogram prawdopodobieństwa pensji",
     xlab="Pensja",freq = FALSE,xlim=c(0,200),col="pink")
lines(density(k),
      lwd = 2)
```





Po obserwacji wykresu z zadania 6 możemy zauważyć, że histogram przypomina rozkład gammy. Po pewnych próbach mogłam ustalić wartości alfy oraz bety są one odpowiednio równe:

1.  $\alpha = shape = 4.35$
2.  $\beta = \frac{1}{scale} = 0.(1)$